

AI 模型分工方案 — 国内外模型最优配置 (终极修改版)

目标: 用满 GitHub Copilot Max + 国内模型不限预算, 把 v9.1 量化系统开发到最完美
生成时间: 2026-09-12 (基于 2026-09-11 版根据最新 Copilot 模型下架/升级规则及系统遗漏模块全面修正)
依据: 对系统 136+ 核心模块、配置、回测内核、机器学习训练链、AI 对冲基金、风控链的深度扫描

目录

- 1. [核心分工原则](#)
- 2. [模型武器库 \(2026-09 最新实测矩阵\)](#)
- 3. [系统模块规模盘点](#)
- 4. [逐模块分配矩阵 \(完整执行清单\)](#)
- 5. [VS Code 多模型自动切换配置 \(修正版\)](#)
- 6. [验证策略与质量门](#)
- 7. [冲突解决机制](#)
- 8. [成本-质量权衡矩阵](#)
- 9. [分阶段推进计划 \(Wave\)](#)
- 10. [禁忌 \(违反即返工\)](#)
- 11. [Prompt 模板库](#)
- 12. [需核实项 \(落地前确认\)](#)
- 附录: [一句话总结](#)

1. 核心分工原则

1.1 能力对比

维度	国外模型 (Claude Sonnet 5 / Opus 5 / GPT-5.6 via Copilot Max)	国内模型 (Qwen3-Max / GLM-5.3 / DeepSeek-V4 / DeepSeek-R1)
强项	复杂架构设计、设计模式、通用算法、代码重构、LangGraph 编排、防时序泄漏	中国市场监管规则、Wind 接口细节、中文注释/文档、政策语义(十五五/社保)、A 股特有逻辑、数学推导
弱项	A 股特有规则(涨跌停/复权/交割)、中文政策语义、Wind	复杂多 Agent 编排、大规模跨仓重构、泛化架构

	MCP 细节	
--	--------	--

1.2 五条决策规则

- 1. 正确性致命度优先: 涉及“真金白银 / 一刀毙命”的代码(执行器、风控门、回测内核撮合、因子表达式求值、LGBM 特征防泄漏)一律国外模型主笔 + 双审[cite: 1]。
- 2. 跨文件复杂度优先: 需要同时改 ≥5 个文件、或依赖 100K+ 行上下文的重构, 交给 Claude Opus 5 / GPT-5.6 Terra / Gemini 3.8 Flash (长上下文)[cite: 1]。
- 3. 英文生态优先国外: 对接 Wind/TDX/AKShare/qlib/stumpy/pyfolio/empyrical 等 SDK 与算法库时, 国外模型对 API 与惯用法更准[cite: 1]。
- 4. 数学推理与中文语义优先国内: 因子数学公式推导首选 DeepSeek-R1; A 股规则、合规、中文报告、中文 UI、批量脚手架、实时信号——国内模型更贴领域且无限预算可放量。
- 5. 国外收口质量门: 国内模型生成的“关键路径代码”必须过一道国外模型 review (Claude Opus 5 安全审计 / GPT-5.6 Sol 单测补全), 否则不入主干[cite: 1]。

2. 模型武器库 (2026-09 最新实测矩阵)

数据来源: GitHub Copilot 模型选择器及厂商 API 最新核对 (已清除已停用的 Sonnet 4.x / Gemini 3.5 早期版)

标注: ★ = 系统推荐主力; 🧠 = 代码专用; ⚡ = 快速低成本; 📖 = 长上下文

2.1 国外模型 (GitHub Copilot Max — 原生接入 VS Code)

第一梯队: 复杂架构/安全审计/核心算力 (资金相关, 必须用)

模型	核心优势	在本系统的最佳用场	优先级
Anthropic Claude Opus 5 ★	最新一代旗舰推理、超长上下文、Agent 工具调用、安全审计最高标准	交易执行器、风控门、LGBM 特征防泄漏审计、管道重构、安全审计、最终 Review	P0
Anthropic Claude Opus 4.8 ★	成熟 Opus 节点, 高稳定性推理	与 Opus 5 互为备选, 关键路径双审	P0
Anthropic Claude Sonnet 5 ★	当前默认主力, 高效平衡, 代码理解极强	日常编码主力 (全面替代已停用 Sonnet 4.x)、架构重构、回测引擎	P0

OpenAI GPT-5.6 Sol ⭐	算法与数值正确性强	因子表达式引擎、回测撮合内核、LightGBM 训练、定价公式	P0
OpenAI GPT-5.6 Terra ⭐	GPT 多模态旗舰，长上下文理解	通读 108KB 管道 /63KB 执行器、跨仓架构深度重构	P0

第二梯队: 代码专用/快速迭代 (高频使用)

模型	核心优势	在本系统的最佳用场	优先级
OpenAI GPT-5.4 🧠	高质量代码生成, 技术债修复	因子批量实现、utils 胶水代码、scripts 自动化	P1
OpenAI GPT-5.3-Codex 🧠	Codex 最新版, 精细代码生成与补全	纯代码任务、函数实现、单元测试生成	P1
Microsoft MAI-Code-1.1-Flash 🧠	微软代码专用, 快速高质量	批量代码生成、函数补全、轻量重构	P1

第三梯队: 长上下文与批量生成

模型	核心优势	在本系统的最佳用场	优先级
Google Gemini 3.8 Flash 📖 ⭐	最新长上下文 Flash , 支持 1M+ Token, 速度极快	通读 242K utils、qlib 75K 依赖架构分析 (替代已弃用的 3.5/3.6)	P1
Anthropic Claude Haiku 4.5 ⚡	极快、成本优	批量注释、日志生成、简单函数、文档	P2

		字符串	
OpenAI GPT-5.4 mini ⚡	快速轻量	简单函数、变量命名、单行补全	P2

2.2 国内模型 (BYOK, OpenAI 兼容端点, 不限预算)

模型	核心优势	在本系统的最佳用场	优先级
DeepSeek-R1 / R2 (深度推理) ★	逻辑与数学 Reasoning Chain	因子逻辑推导 (Alpha101/GTJA19 1 数学表达)、收益归因推导、定价公式	P0
智谱 GLM-5.3 / 5.4 ★	工程智能体最强、中文金融语义好	AI 决策 (GLM-5 盘中)、AI Hedge Fund 20 分析师 LangGraph	P0
DeepSeek V4 Pro / V3.2 ★	通用代码吞吐大、质量高	因子代码批量向量化、scripts 自动化、utils 胶水代码	P0
阿里 Qwen3-Max ★	中英均衡、中文金融语义与政策分析	中文 UI 页、中文报告模板、宏观十五五/社保 ETF	P0
字节 豆包 (Doubao Seed) ⚡	高吞吐、低延迟	运维脚本、日志监控、测试用例批处理	P1
Kimi (Moonshot K3) 📖	超长上下文窗口	通读大型长文档、跨文件语义归因	P1

2.3 选型决策树

开始编码任务

- 资金安全/回测内核/特征泄漏相关?(执行器/风控/回测内核/lgb_trainer)
 - └ 是 → Claude Opus 5 主笔 + GPT-5.6 Sol 双审
- 因子数学推导与逻辑推演?
 - └ 是 → DeepSeek-R1 (生成数学表达式) → Claude Sonnet 5 (Python 向量化代码)
- 跨文件重构?(≥5 文件 或 100K+ 上下文)
 - └ 是 → Claude Opus 5 / Gemini 3.8 Flash
- 中文语义重?(政策/报告/UI/文档)
 - └ 是 → Qwen3-Max / GLM-5.3
- 批量/快速/低成本?(脚本/测试)
 - └ 是 → DeepSeek V4 / Doubao Seed
- └ 日常通用编码 → Claude Sonnet 5

3. 系统模块规模盘点

来自全仓 LOC 最新扫描 (共 2,181 个 .py / ≈740K 行):

子系统	代码行	文件数	性质	核心风险与要求
utils (工具/胶水/LLM 路由)	242K	552	量大、杂	接口一致性
tests (测试)	242K	644	质量关键	覆盖率 ≥80%
qlib (vendored 依赖)	75K	335	第三方, 勿重写	升级评估
scripts (自动化)	57K	203	运维向	可执行率 100%
ms_strategy (策略主体与因子)	25K	84	收益核心	因子 IC/IR 及向量化计算

quant_modules (因子/模块)	22K	73	业务逻辑	降级链与数据对齐
ai_decision (AI 对冲基金)	9K	23	Agent 编排	无死锁与响应延迟 <500ms
ui (Streamlit 17 页)	6.9K	32	中文交互	无乱码、展示完整
cli (统一入口)	5.8K	45	多模式编排	命令行可用性
backtests (回测引擎内核)	5.4K	16	致命正确性	撮合、滑点、无未来函数
lgb_trainer (机器学习训练)	4.2K	11	致命正确性	严格防范时序数据泄漏
data (数据采集/降级)	4.2K	9	数据源	P0-P6 降级容错
external (外部 SDK)	8.2K	34	接口对接	协议完整性
reporting (报告引擎)	2.9K	8	成果输出	中文金融格式

4. 逐模块分配矩阵 (完整执行清单)

标注: [外]=Copilot Max 国外模型主笔; [国]=国内模型主笔; [混]=协同主笔

4.1 国外模型主导 (资金安全 + 架构复杂 + 核心正确性)

#	模块 / 文件	规模	首选模型	备选模型	验收标准
1	executor/ (实盘指令生成)	1.1K	[外] Claude Opus 5	GPT-5.6 Sol	安全审计通过 + 单测覆盖率 100%

2	institutional_pipeline_runner.py	108K	[外] Gemini 3.8 Flash →Opus 5	GPT-5.6 Terra	拆分为 ≤5KB/文件, 高内聚低耦合
3	daily_trade_executor.py	63K	[外] Claude Opus 5	GPT-5.6 Sol	通过风控门与异常阻断测试
4	run_daily_eod.py (风控四 Guard 链)	5.8K	[外] Claude Opus 5	GPT-5.6 Sol	KillSwitch 阻断测试 100% 触发
5	backtests/engine/ (回测撮合内核)	5.4K	[外] GPT-5.6 Sol	Claude Opus 5	零未来函数、撮合与滑点精确复现
6	lgb_trainer / (特征工程与训练)	4.2K	[外] Claude Opus 5	GPT-5.6 Sol	通过时序数据泄漏审查 (No Leakage)
7	utils/hedge_engine.py (Beta 对冲)	3.2K	[外] GPT-5.6 Sol	Claude Sonnet 5	Beta 计算单测精度通过
8	utils/hedge_rebalance_integrator.py	2.8K	[外] Claude Opus 5	GPT-5.6 Sol	状态机转换测试通过
9	scripts/run_200w_etf_backtest.py	4.5K	[外] GPT-5.6 Sol	Claude Sonnet 5	数值计算复核通过
10	quant_modules/data_l	2.1K	[外] Claude	GPT-5.4	P0-P6 降级 链断网/异常

	ayer.py		Sonnet 5		全覆盖
--	---------	--	----------	--	-----

4.2 国内模型主导 (中文语义 + 数学推理 + 批处理)

#	模块 / 文件	规模	首选模型	备选模型	验收标准
11	ms_strategy/src/alpha / (因子表达式推导)	8.2K	[国] DeepSeek-R1 (推导)	GPT-5.6 Sol	公式推导无误, IC/IR 显著为正
12	utils/glm5_decision_engine.py	1.9K	[国] GLM-5.3	GLM-5.4	盘中决策延迟 <500ms
13	quant_modules/ai_hedge_fund/ (Agent 编排)	9K	[国] GLM-5.3	DeepSeek-V4	分析师 LangGraph 链路无死锁
14	utils/kondratiev_cycle.py (康波周期)	1.5K	[国] Qwen3-Max	GLM-5.3	宏观周期判定逻辑正确
15	utils/five_year_plan.py (十五五评分)	1.1K	[国] Qwen3-Max	GLM-5.3	政策语义映射合理
16	utils/social_security_etf.py (社保ETF)	1.3K	[国] Qwen3-Max	GLM-5.3	国家队持仓追踪准确
17	tools/wind_mcp_fetcher.py	2.4K	[国] DeepSeek-	GLM-5.3	复权/错误码处理完全覆

	(Wind 接口)		V4		盖
18	ui/ (Streamlit 面板)	6.9K	[国] Qwen3-Ma x	豆包	页面无卡顿 ， 中文渲染 无乱码
19	reporting/ (中文报告引擎)	2.9K	[国] Qwen3-Ma x	GLM-5.3	金融格式合 规， 排版规 范
20	scripts/ (运 维与自动化)	57K	[国] DeepSeek- V4	豆包	执行无阻断 错误
21	tests/ (批量 测试套件)	242K	[国] DeepSeek- V4	豆包	语法与基础 覆盖率为 100%

4.3 混合协作 (国内外分工交叉审查)

#	模块 / 文件	国外职责	国内职责	验收标准
22	ms_strategy/s rc/alpha/ (因子 代码实现)	代码矩阵向量 化与性能优化	因子数学逻辑 与表达式设计	运行速度提升 3x 以上
23	config/portfoli o_200w_etf_v 91.yaml	结构/熔断/期权 参数段	宏观/社保/十五 五政策语义段	加载语法校验 通过
24	utils/ (胶水代 码库)	架构设计、接 口抽象与定义	批量底层实现 与中文 Docstring	类型系统 mypy 校验零错误
25	cli/ (统一入口)	顶层命令编排 与分发	命令行参数解 析与中文 Help	所有子命令运 行畅通

5. VS Code 多模型自动切换配置 (修正版)

5.1 插件安装要求

插件	用途	优先级
GitHub Copilot	国外模型主力编码 (自动登录系统凭据)	P0
GitHub Copilot Chat	Agent 模式对话与重构	P0
Continue.dev	国内模型按路径分发路由	P0

5.2 完整 .vscode/settings.json (可直接复制)

代码段

```
// .vscode/settings.json — AI 模型分工终极配置 (2026-09 修正版)
{
  //
  //
  // 第一部分: GitHub Copilot (国外原生配置)
  //
  // 主力模型全面升级为 Sonnet 5 (停用已废弃的 Sonnet 4.x)
  "github.copilot.selectedModel": "claude-sonnet-5",
  "github.copilot.chat.agent.enabled": true,
  "github.copilot.editor.enableAutoCompletions": true,
  //
  // 第二部分: Continue.dev (国产与特殊模型接入)
```

```
"continue.enableTabAutocomplete": true,
"continue.enableCodeLens": true,

"continue.models": [
  {
    "title": "DeepSeek-R1",
    "provider": "openai",
    "model": "deepseek-reasoner",
    "apiBase": "https://api.deepseek.com/v1",
    "apiKey": "${env:DEEPSEEK_API_KEY}",
    "contextLength": 64000,
    "systemMessage": "你是数学与逻辑推理专家，擅长量化因子逻辑推导与数学表达式构建。"
  },
  {
    "title": "GLM-5.3",
    "provider": "openai",
    "model": "glm-5.3",
    "apiBase": "https://open.bigmodel.cn/api/paas/v4",
    "apiKey": "${env:GLM_API_KEY}",
    "contextLength": 128000,
    "systemMessage": "你是量化系统 Agent 编排专家，精通 A 股规则与多 Agent 协作。"
  },
  {
    "title": "DeepSeek-V4",
    "provider": "openai",
    "model": "deepseek-chat",
    "apiBase": "https://api.deepseek.com/v1",
    "apiKey": "${env:DEEPSEEK_API_KEY}",
    "contextLength": 64000,
    "systemMessage": "你是高效代码生成专家，擅长批量实现与代码向量化优化。"
  },
  {
    "title": "Qwen3-Max",
    "provider": "openai",
    "model": "qwen-max-latest",
    "apiBase": "https://dashscope.aliyuncs.com/compatible-mode/v1",
    "apiKey": "${env:DASHSCOPE_API_KEY}",
    "contextLength": 32768,
    "systemMessage": "你是中文金融领域专家，精通政策语义理解与报告生成。"
  }
]
```

```

],

//
=====

// 第三部分: 规则路由 (聚合优化版)
//
=====

"continue.rules": [
  // — 资金三件套 / 回测内核 / 特征训练 → 国外模型 —
  {"path": "{executor/**,run_daily_eod.py,backtests/engine/**,lgb_trainer/**}", "model":
"claude-sonnet-5", "autoSelect": true},

  // — 架构重构 → 国外模型 —
  {"path":
"{institutional_pipeline_runner.py,daily_trade_executor.py,quant_modules/data_layer.py}",
"model": "claude-sonnet-5", "autoSelect": true},

  // — 因子逻辑推导 → DeepSeek-R1 —
  {"path": "ms_strategy/src/alpha/**", "model": "DeepSeek-R1", "autoSelect": true},

  // — AI Agent 决策 → GLM-5.3 —
  {"path": "{quant_modules/ai_hedge_fund/**,utils/glm5_*.py}", "model": "GLM-5.3", "autoSelect":
true},

  // — 政策/UI/报告 → Qwen3-Max —
  {"path":
"{ui/**,reporting/**,utils/kondratiev_cycle.py,utils/five_year_plan.py,utils/social_security_etf.py}",
"model": "Qwen3-Max", "autoSelect": true},

  // — 批量自动化脚本与测试 → DeepSeek-V4 —
  {"path": "{scripts/**,tests/**,tools/wind_mcp_fetcher.py}", "model": "DeepSeek-V4",
"autoSelect": true}
]
}

```

6. 验证策略与质量门

6.1 审查流水线 (CI/CD 触发)

[代码提交]

- 涉及致命路径 (#1 - #10)?
 - └ 是 → 自动触发 Claude Opus 5 安全与时序泄漏审查脚本
- 因子表达推导 (#11)?
 - └ 是 → 跑 pytest 对齐数学解与向量化代码结果
- └ 全量触发 → Mypy 类型检查 + Ruff Lint + Pytest 自动化测试套件

7. 冲突解决机制

7.1 裁决规则表

争议场景	国内模型主张	国外模型主张	最终裁决标准
特征工程	追求高 AUC 的特征工程写法	认定存在时序数据泄漏	严禁泄漏，采纳国外模型
回测撮合	简化挂单撮合机制	严格按 Tick 级最高/最低价判断	采纳国外模型严格撮合
A股政策指标	严格映射“十五五”产业词表	泛化为通用行业 classification	采纳国内模型精准语义
Wind 报错	硬编码兼容特殊错误码	抛出抽象底层异常	采纳国内模型业务处理

8. 成本-质量权衡矩阵

任务类别	推荐核心模型	替换兜底模型	预算权重
资金风控/核心内核	Claude Opus 5	GPT-5.6 Sol	Copilot 包月包含
回测与 ML 防泄漏	GPT-5.6 Sol	Claude Opus 5	Copilot 包月包含

因子数学推导	DeepSeek-R1	GPT-5.6 Sol	按量付费 (极低)
Agent 复杂编排	GLM-5.3	Claude Sonnet 5	按量付费 (中等)
批量生成/测试脚本	DeepSeek V4	豆包 Seed	按量付费 (极低)

9. 分阶段推进计划 (Wave)

阶段	周期	核心重点	主导模型	交付与验收
Wave A: 致命加固	W1 - W2	资金三件套、风控链、回测内核、lgb_trainer 防泄漏	Claude Opus 5 + GPT-5.6 Sol	零高危漏洞, 无时序泄漏[cite: 1]
Wave B: 架构重构	W3 - W5	108KB 管道解耦拆分, 接口抽象	Gemini 3.8 Flash + Sonnet 5	拆分为 ≤5KB 模块[cite: 1]
Wave C: 因子与 Agent	W6 - W7	DeepSeek-R1 因子推导 + LangGraph 编排	DeepSeek-R1 + GLM-5.3	因子 Alpha 提升 3x, Agent 无死锁
Wave D: 数据与 UI	W8	Wind 接口完善、Streamlit 面板及中文报告	DeepSeek-V4 + Qwen3-Max	中文显示与报告自动化全闭环[cite: 1]

10. 禁忌 (违反即返工)

- 1. **✗** 严禁使用已停用的模型版本: 如 claude-sonnet-4 或 gemini-3.5-flash, 会导致配置失效回退。
- 2. **✗** 严禁国内模型未经国外 **Review** 直合致命路径: 执行器、风控门、回测撮合逻辑必须过 Claude Opus 5 安全审计[cite: 1]。
- 3. **✗** 严禁用国外模型强行翻译中文政策: “十五五”或社保 ETF 逻辑用国外模型容易带来概念泛化与偏差[cite: 1]。
- 4. **✗** 严禁忽视机器学习数据泄漏: 在 lgb_trainer/ 模块重构时, 严禁使用非严格时间截面的未

来特征[cite: 1]。

11. Prompt 模板库 (新增 ML 防泄漏模板)

11.1 时序数据泄漏审计 Prompt (专用于 lgb_trainer)

Plaintext
你是量化机器学习与数据安全专家。请对以下特征工程与模型训练代码进行严格的时序数据泄漏 (Data Leakage) 审计：

代码片段
{code}

- ## 重点检查项
- 1. 交叉验证是否使用了 K-Fold (时序数据严禁使用标准 K-Fold, 必须使用 TimeSeriesSplit)
 - 2. 标准化/归一化 (Scaler) 是否在 Train/Val 分割前拟合 (Fit)
 - 3. 因子计算中是否使用了 t+1 及以后的收盘价/信息
 - 4. 滞后特征 (Lag Target) 计算是否存在 Shift 位移方向错误

输出要求
指出所有潜在泄漏点并提供修正代码。

12. 需核实项 (落地前确认)

#	核实项	确认动作	优先级
1	VS Code 环境变量解析	确保终端执行 echo \$DEEPSEEK_API_KEY 能够正确打印凭据	P0
2	Copilot Max 最新模型可用性	打开 VS Code 命令行执行 Copilot: Select Model 确保 Opus 5 / Sonnet 5 在列表中	P0
3	Mypy 环境依赖	确认开发环境中已安装并配置好项目	P1

		mypy 规则集	
--	--	----------	--

附录: 一句话总结

国外模型 (Copilot Max / Claude Opus 5 / Sonnet 5 / GPT-5.6) 守住“资金安全、回测内核、架构解耦、ML 防泄漏”四大红线, 占 70% 关键代码[cite: 1];
国内模型 (DeepSeek-R1 / GLM-5.3 / Qwen3-Max / DeepSeek-V4) 攻克“因子公式推导、Agent 编排、中文政策语义、Wind 接口与批量生成”, 占 30% 关键逻辑与全部中文输出。